A operação estrela compensa seu custo em Adult?

Relatório da Q5 • 13 de outubro de 2026 • Português brasileiro

1. A pergunta

A Q5 pergunta se uma camada estrela, formada pelo produto elemento a elemento de dois ramos afins, oferece mais acurácia por FLOP que uma camada densa ReLU mais larga, e se a resposta muda com a largura. Investigamos a classificação de renda no Adult com o motor NumPy/CPU do BERT-CPU, pareando estrela de largura h e denso de largura 2h. Mantemos épocas, otimizador, taxa e sementes. 'FLOPs iguais' é uma aproximação, pois a rede inteira inclui a saída; publicamos os custos efetivos, um controle de teto de inferência e a comparação soma versus produto com os mesmos dois ramos.

2. O que a literatura diz

Ma et al. [1] — Rewrite the Stars. A multiplicação de projeções cria interações entre atributos sem construir explicitamente a expansão de monômios. Em redes de visão, o artigo observa ganhos ao substituir soma por produto e sugere maior utilidade em redes estreitas. A previsão transferida para Adult é uma vantagem da estrela nas larguras pequenas. Essa previsão é uma inferência: o trabalho usa blocos de visão, convoluções e outra escala; não mede esta MLP tabular. O controle Soma aproxima a ablação do artigo, enquanto Denso 2h responde à pergunta específica do notebook.

Shazeer [2] — GLU Variants Improve Transformer. ReGLU tem a mesma forma algébrica da nossa estrela-ReLU; GEGLU e SwiGLU trocam a ativação de um ramo. O trabalho observa melhor perplexidade para algumas variantes no T5 e ajusta larguras para manter aproximadamente custo e parâmetros. Isso motiva nossa extensão com GLU, GEGLU e SwiGLU, mas não estabelece uma ordem universal de acurácia em Adult. Estrela e ReGLU não são contadas como arquiteturas diferentes.

Dauphin et al. [3] — Gated Convolutional Networks. A GLU combina um ramo linear com uma porta sigmoide. O caminho linear dispensa uma derivada adicional de ativação naquele ramo, favorecendo a propagação de gradientes nos modelos estudados. A extrapolação verificável é que a porta afete convergência e estabilidade. A vantagem de paralelização em linguagem não é uma previsão de velocidade para nossas MLPs em CPU.

Grinsztajn et al. [4] — Modelos tabulares. Em 45 bases, o estudo analisa orientação dos atributos, atributos pouco informativos e irregularidade das funções como fatores relevantes para a vantagem de árvores. Produtos entre features podem ajudar algumas interações, mas não eliminam esses fatores. Em indicadores one-hot, quadrados repetem o próprio indicador e produtos entre categorias exclusivas são zero. As ablações por tipo de atributo testam compatibilidade com a explicação por interações; não identificam sua causa nem comparam a estrela com árvores, que não foram treinadas aqui.

As quatro fontes primárias, suas previsões e os limites de extrapolação estão detalhados em `literatura.md`; as referências completas aparecem ao final. A pergunta permanece empírica: capacidade representacional adicional não garante melhor generalização no mesmo protocolo de otimização.

Há ainda uma particularidade matemática deste domínio: para indicadores binários, $\mathrm{ReLU}(x_i + x_j - 1) = x_i x_j$. Assim, uma unidade ReLU comum já representa a coocorrência de dois indicadores. A derivada mista nula dentro de regiões contínuas não impede representar essa interação no domínio discreto. O produto explícito não garante uma vantagem exclusiva nas categorias.

3. Hipótese

H1, registrada antes dos experimentos: em h=32 e h=64, estrela-ReLU supera denso-2h por pelo menos 0,3 ponto percentual na acurácia média de teste, com separação dos intervalos média ± desvio-padrão amostral. A condição é conjuntiva: precisa ocorrer nas duas larguras. O limiar é uma escolha operacional deste estudo, não uma previsão numérica dos artigos.

H2, secundária: a vantagem estrela−denso é maior usando somente indicadores categóricos que usando somente atributos contínuos. Para examinar essa direção, calculamos também a diferença das diferenças por semente. Um contraste positivo é compatível com a hipótese; três sementes e mudanças na informação disponível impedem uma conclusão causal.

O texto em `protocolo.md` foi escrito antes do primeiro treino. Seu SHA-256 começa por `c152ebabe9f4dda9`; o valor integral e os hashes do código e dos dados estão em `resultados/ambiente.json`. Esse registro local torna alterações detectáveis dentro da entrega, mas não equivale a um pré-registro externo independente.

4. O que foi implementado

`modelos.py` implementa seis famílias com operações já diferenciadas pelo motor: denso, estrela/ReGLU, soma, GLU, GEGLU e SwiGLU. O denso no teto reutiliza a família densa com largura calculada. Os ramos usam Xavier, vieses zero e a mesma saída. `executar.py` direciona ao executor sequencial protegido, que chama `run_adult` sem alterar o instrumento. O hook coleta grafos a cada época, sem mudar operações numéricas; a referência e suas curvas foram novamente verificadas. Os primeiros 51 treinos pertencem à execução histórica; os demais usam os controles descritos em `adendo_recursos.md`.

As portas são ReLU(u), sigmoide(u), GELU(u) e u·sigmoide(u). GELU usa a aproximação por tanh do motor; SwiGLU fixa β=1. Na soma, combinamos ReLU(u)+v; nas portas, g(u)·v. Com entrada de dimensão d e lote B, os ramos têm pesos (d+1)×h e ativações h×B; a saída tem pesos (h+1)×2. A seleção preserva a ordem do carregador: seis contínuos, depois 102 indicadores.

$$u = W_1^\top \widetilde{X}, \quad v = W_2^\top \widetilde{X}, \quad A_\star = \mathrm{ReLU}(u) \odot v.$$

X̃ acrescenta uma linha de uns sobre X; cada exemplo é uma coluna e o viés ocupa a primeira linha dos pesos. A saída produz dois logits, usados com softmax e entropia cruzada categórica. As derivadas locais da estrela são:

$$\frac{\partial J}{\partial u} = \frac{\partial J}{\partial A} \odot v \odot \mathbf{1}_{u>0}, \qquad \frac{\partial J}{\partial v} = \frac{\partial J}{\partial A} \odot \mathrm{ReLU}(u).$$

$$\frac{\partial J}{\partial W_1} = \widetilde{X} \left(\frac{\partial J}{\partial u}\right)^\top, \qquad \frac{\partial J}{\partial W_2} = \widetilde{X} \left(\frac{\partial J}{\partial v}\right)^\top.$$

Na região u>0, um neurônio estrela produz $(a^\top \tilde{x})(b^\top \tilde{x})$, incluindo termos cruzados. Com ReLU, o resultado é quadrático por partes. Os coeficientes não são todos independentes: a matriz quadrática simétrica $(ab^\top + ba^\top)/2$ tem posto no máximo dois por unidade. Uma MLP ReLU comum também produz dependências entre atributos, mas seus logits são afins dentro de cada região de ativação.

Verificação: 7 testes aprovados; 333 coordenadas de entradas, pesos e vieses comparadas com diferenças centrais de passo 10^{-6}. Erro absoluto máximo: 1.4831e-10. O oráculo de forward é NumPy independente, com pontos afastados da fronteira da ReLU. Também verificamos gradientes nulos nos atributos excluídos, equivalência do denso com a referência e fórmulas de custo. Não foi criado um novo operador primitivo de autograd.

Os arquivos de análise, auditoria e geração do relatório completam a implementação. A tabela de linhas de código na seção 9 explicita o tamanho da entrega. Resultados individuais, pesos finais e curvas de 100 épocas acompanham todas as configurações, permitindo inspecionar cada número das tabelas.

5. Protocolo

Tabela 1 — Condições fixadas

Item	Valor
Treino / validação / teste	26.049 / 6.512 / 16.281
Entradas completas	6 contínuas + 102 indicadores
Larguras h	16, 32, 64, 128
Sementes	0, 1, 2
Épocas / lote	100 / treino inteiro
Otimizador / taxa	Adam / 0,01
Betas / epsilon	0,9; 0,999 / 10^{-8}
Precisão / decaimento	float64 / zero
Grade / verificações adicionais	156 + referência + equivalência

O treino oficial tem 32.561 exemplos. A mesma permutação por semente separa 20% para validação antes da inicialização das arquiteturas. Não houve ajuste da taxa, escolha de checkpoint, early stopping ou seleção de largura pelo teste. Avaliamos todos os modelos após a época 100. A semente compartilhada pareia as divisões, mas não gera pesos idênticos em arquiteturas de formas diferentes. O DP reflete simultaneamente mudança de divisão e inicialização.

No bloco completo, a grade contém sete configurações por largura: as seis famílias e o denso no teto. Nos blocos contínuo e categórico, contém estrela, denso-2h e denso no teto. São 84 treinos completos e 72 de ablação. A hipótese principal usa o pareamento h:2h; o controle soma mantém exatamente parâmetros e custo contado; as demais comparações são extensões declaradas, publicadas integralmente.

$$C_{\text{denso}}(m) = (2d+7)m + 4, \qquad C_{\star}(h) = C_{\text{soma}}(h) = (4d+10)h + 4.$$

Essas fórmulas dão o custo de inferência por exemplo conforme o motor, incluindo as duas classes, vieses, ReLU e combinação. Multiplicamos por 16.281 para obter o custo de uma passagem no teste. Em d=108, estrela custa 442h+4 e denso-2h custa 446h+4: cerca de 0,90% de diferença. Com seis contínuos, são 34h+4 e 38h+4, diferença próxima de 10,5%. Assim, o controle de teto é particularmente relevante nessa ablação.

$$m_{\text{teto}} = \left\lfloor \frac{(4d+10)h}{2d+7} \right\rfloor .$$

O controle escolhe a maior largura densa inteira que cabe no custo da estrela. Trata-se do mesmo teto de inferência, com custo usado ligeiramente diferente por arredondamento; não de igualdade artificial obtida adicionando operações inúteis. Para treino T e validação V, os custos por época são:

$$F_d = [(4d+17)m + 26]T + [(2d+7)m + 18]V + 4,$$

$$F_{\star} = [(8d+22)h + 26]T + [(4d+10)h + 18]V + 4.$$

O contador inclui forward, backward dos produtos matriciais e forward/perda de validação; omite a aritmética NumPy do Adam e o backward elementar. Reportamos essa convenção, não o total físico exato. O orçamento fixado é de épocas; treino e inferência não são intercambiáveis. As variantes GLU também pagam o custo contado de suas ativações.

Reportamos média ± DP amostral (ddof=1). Para a diferença de acurácia, subtraímos resultados com a mesma semente e calculamos IC t de 95%, com 2 graus de liberdade. Esse IC é descritivo, depende de aproximação de normalidade e não corrige múltiplas comparações. A decisão de H1 segue sua regra registrada. A classificação adicional ‘vantagem clara’ exige separação das barras e IC que exclua zero; sobreposição não prova equivalência. Usamos `summarize()` sem seu diagnóstico automático e `pareto()` com fronteira das médias explicitamente descritiva.

6. Resultados

Referência reproduzida. O denso 64 com semente 0 atingiu 85,4309% no teste, 84,2277822 GFLOPs de treino e 232,427556 MFLOPs de inferência. O denso 64 da grade (h=32) reproduziu exatamente essa acurácia e esses custos. Sua média nas três sementes é 85,472 ± 0,158%. A auditoria reconstruiu três inferências a partir dos pesos publicados e conferiu custos, parâmetros, curvas e arquivos das 156 execuções.

Resposta à pergunta principal. A hipótese H1 não foi atendida pela regra registrada. A diferença média estrela−denso-2h varia de -0,934 a 0,029 p.p. nas quatro larguras (Tabela 3). A conclusão é condicionada ao protocolo de 100 épocas e Adam com taxa fixa; não estima o melhor desempenho possível de cada arquitetura.

Em h=16, a pequena diferença positiva não se distingue do ruído. Em h=32, a média favorece o denso, mas o IC pareado ainda inclui zero. Em h=64 e h=128, o denso é favorecido pelos dois critérios declarados. Portanto, o resultado depende da largura: ampliar a estrela não recupera uma vantagem; sua diferença relativa piora nesta grade (Tabela 3).

Tabela 2 — Dados completos; teste: média ± DP; treino: média

h	Modelo (larg.)	Treino (%)	Teste (%)	Treino GF	Infer. MF	Parâm.
16	Denso 2h (32)	86,770	85,462 ± 0,132	42,15	116,25	3554
16	Estrela (16)	86,872	85,490 ± 0,124	41,61	115,20	3522
16	Soma (16)	86,072	85,570 ± 0,092	41,61	115,20	3522
32	Denso 2h (64)	86,899	85,472 ± 0,158	84,23	232,43	7106
32	Estrela (32)	87,590	85,095 ± 0,199	83,14	230,34	7042
32	Soma (32)	86,495	85,687 ± 0,088	83,14	230,34	7042
64	Denso 2h (128)	87,500	85,374 ± 0,079	168,38	464,79	14210
64	Estrela (64)	88,346	84,808 ± 0,302	166,21	460,62	14082
64	Soma (64)	86,588	85,627 ± 0,083	166,21	460,62	14082
128	Denso 2h (256)	87,829	85,204 ± 0,103	336,67	929,51	28418
128	Estrela (128)	89,173	84,270 ± 0,089	332,34	921,18	28162
128	Soma (128)	86,625	85,715 ± 0,038	332,34	921,18	28162

Ao ampliar a estrela de 16 para 128, a acurácia média de treino sobe de 86,872% para 89,173%, enquanto a de teste cai (Tabela 2). Esse padrão é compatível com sobreajuste; não distingue sozinho capacidade excessiva, escala das ativações e configuração de otimização.

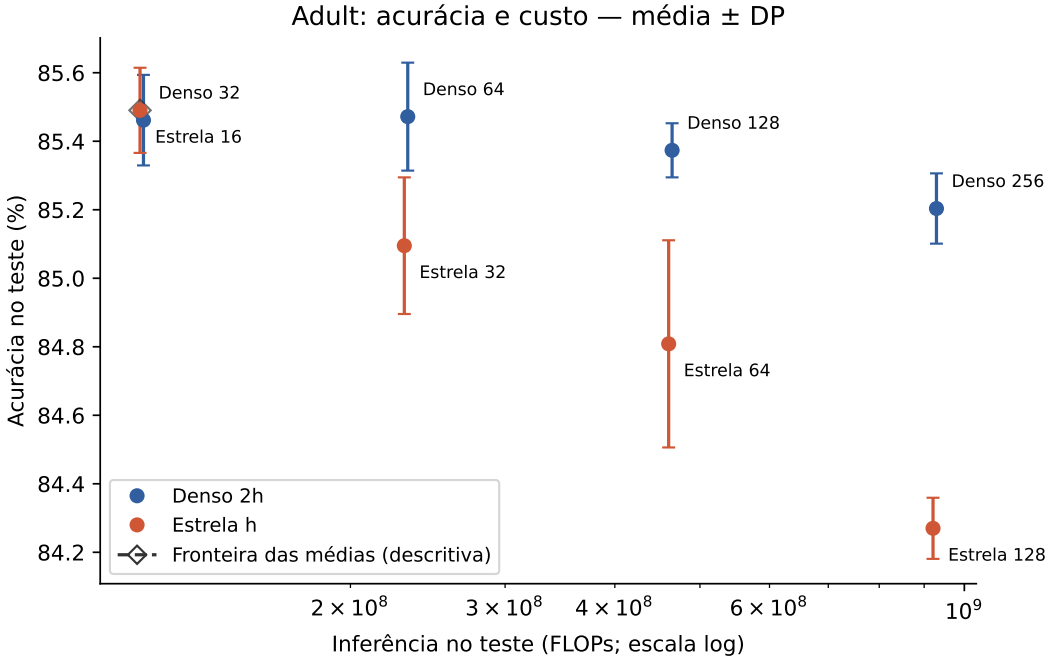


Figura 1 — Pareto dos modelos principais. Barras: DP; diamantes: fronteira das médias, sem teste de dominância.

A Tabela 7 reproduz `summarize()` para as 52 configurações. Em `resultados/`, os arquivos `resumo.csv` e `execucoes.csv` detalham médias e execuções individuais. A figura correspondente de treino está em `figuras/pareto_treino.pdf`.

Diferenças pareadas, largura e orçamento

Tabela 3 — Estrela menos denso-2h; pontos percentuais

h	Média Δ	DP Δ	IC t 95%	Barras sobrepostas
16	0,029	0,182	[-0,424; 0,481]	sim
32	-0,377	0,212	[-0,903; 0,149]	não
64	-0,565	0,224	[-1,121; -0,009]	não
128	-0,934	0,191	[-1,407; -0,460]	não

Dependência da largura. O contraste pareado (estrela−denso) em h=128 menos o mesmo contraste em h=16 vale -0,962 p.p., com IC t de 95% [-1,822; -0,103] (linhas extremas da Tabela 3; valores por semente em `analise.json`). Ele sugere piora relativa ao aumentar a largura. Essa análise é exploratória, acrescentada após observar a grade principal, sem alterar H1; mantém as limitações de três sementes e comparações múltiplas.

No bloco completo, a estrela usa aproximadamente 99,10% dos FLOPs de inferência e 98,71% dos FLOPs de treino do denso-2h nas quatro larguras; as pequenas variações decorrem dos termos constantes das fórmulas da seção 5. A Tabela 3 quantifica a incerteza da diferença de acurácia; a Tabela 4 verifica a sensibilidade ao teto de custo e à combinação dos ramos.

Tabela 4 — Controles no bloco completo

h	Larg.	Teste teto (%)	Treino GF	Infer. MF	Δ teto	Δ soma
16	31	85,517 ± 0,059	40,84	112,62	-0,027	-0,080
32	63	85,480 ± 0,235	82,91	228,80	-0,385	-0,592
64	126	85,326 ± 0,111	165,75	457,53	-0,518	-0,819
128	253	85,335 ± 0,031	332,73	918,62	-1,065	-1,445

Δ teto e Δ soma significam estrela menos o respectivo controle. A comparação com soma isola a operação de combinação dentro do desenho adotado, mas também muda escala e condicionamento das ativações. Todas as diferenças individuais, seus DPs e ICs estão em `comparacoes.csv`. O arredondamento da largura no teto não permite alegar igualdade exata de custo usado.

O denso no teto também é favorecido em h=64 e h=128 pelos dois critérios; h=16 e h=32 permanecem inconclusivos pela regra conjunta (Tabela 4 e `comparacoes.csv`). Assim, a leitura principal nas larguras maiores persiste ao restringir a inferência densa ao teto da estrela.

Produto versus soma. Com os mesmos parâmetros e FLOPs contados, a soma é favorecida pelos critérios registrados em h=32, 64, 128; o contraste é inconclusivo em h=16 (Tabela 4 e ICs em `comparacoes.csv`). A previsão de vantagem multiplicativa transferida de Ma et al. não foi corroborada nestes pares. Isso delimita a transferência para esta MLP tabular; não refuta os resultados do artigo em visão.

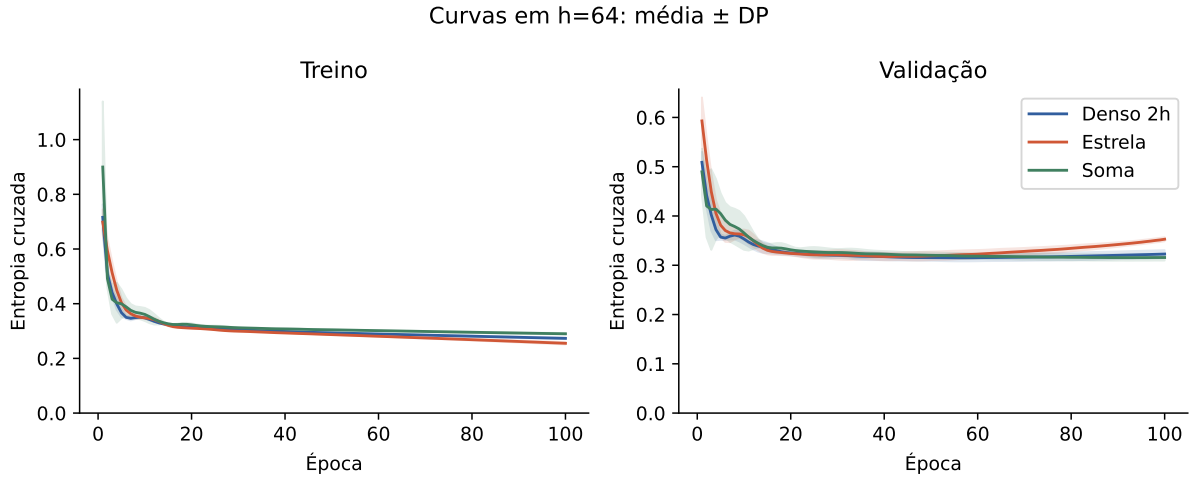


Figura 2 — Curvas em h=64. Treino é medido antes da atualização; validação, depois. Faixas: média ± DP.

As curvas ajudam a distinguir ajuste ao treino de desempenho fora dele. Como a taxa não foi ajustada por família, uma diferença de convergência pode refletir otimização e escala das ativações. A curva de validação não foi usada para escolher a época final; todos os resultados publicados são da época 100.

Portas e ablações dos atributos

Tabela 5 — Portas adicionais; teste (%) ± DP

h	Família	Teste (%)	Treino GF	Infer. MF
16	GLU	85,738 ± 0,027	41,82	116,25
16	GEGLU	85,378 ± 0,080	41,98	117,03
16	SwiGLU	85,447 ± 0,048	41,87	116,51
32	GLU	85,738 ± 0,087	83,56	232,43
32	GEGLU	85,181 ± 0,068	83,87	233,99
32	SwiGLU	85,283 ± 0,075	83,67	232,95
64	GLU	85,609 ± 0,055	167,04	464,79
64	GEGLU	84,970 ± 0,128	167,67	467,92
64	SwiGLU	85,116 ± 0,051	167,25	465,83
128	GLU	85,468 ± 0,006	334,01	929,51
128	GEGLU	84,602 ± 0,144	335,26	935,77
128	SwiGLU	84,837 ± 0,154	334,42	931,60

A maior média descritiva do bloco completo ocorre em GLU em h=16, GLU em h=32, com dispersões e custos publicados na Tabela 5. Essa identificação é pós-experimento; não é seleção validada nem prova de superioridade sobre todas as configurações. A ordenação observada não sustenta transferir diretamente para Adult a expectativa de GEGLU/SwiGLU como melhores portas em linguagem. Os dados completos estão em `resumo.csv` e a visualização em `figuras/variantes.pdf`.

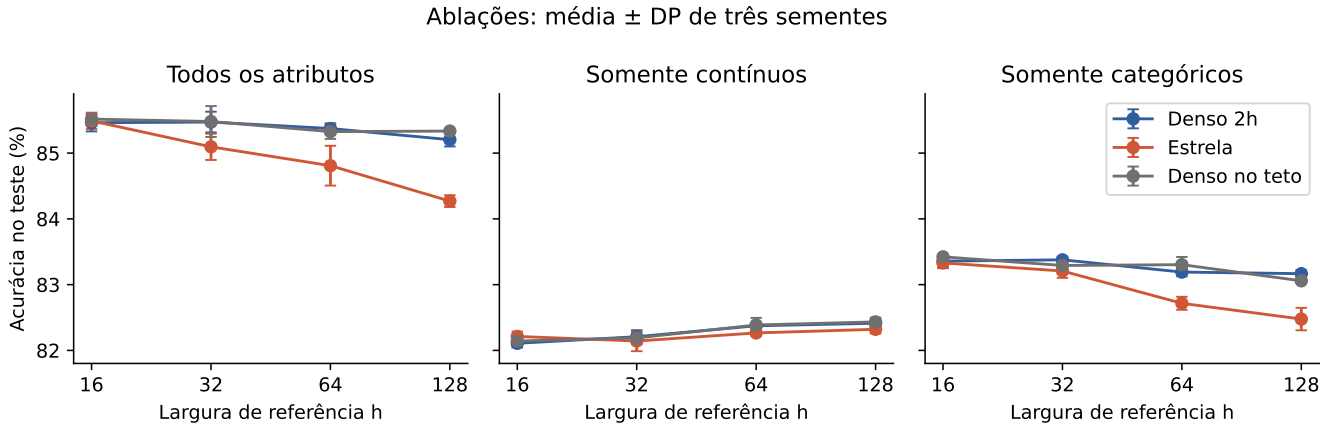


Figura 3 — Mesmas sementes e épocas; informação disponível muda entre blocos. Barras: DP.

Tabela 6 — Hipótese mecanística; pontos percentuais

h	Δ categ.	Δ contín.	Δ categ. − Δ contín.	IC t 95%
16	-0,027	0,104	-0,131	[-0,338; 0,076]
32	-0,170	-0,066	-0,104	[-0,532; 0,324]
64	-0,475	-0,109	-0,366	[-0,603; -0,130]
128	-0,690	-0,092	-0,598	[-1,270; 0,075]

H2 não foi corroborada. As quatro estimativas da diferença das diferenças são negativas, direção oposta à prevista. Em h=64, o IC também fica inteiramente abaixo de zero; nas demais larguras, inclui zero (Tabela 6). Portanto, não há evidência, neste protocolo, de que a vantagem da estrela se concentre nos indicadores categóricos. Os sinais pontuais nas outras larguras não bastam para afirmar o mecanismo inverso.

Cada Δ é estrela−denso-2h. A última diferença é calculada dentro de cada semente antes de obter média e IC. Os contrastes contra o denso no teto também são publicados em `hipotese_mecanistica.csv`. Um sinal favorável a H2 não demonstra que a rede aprendeu interações entre categorias: os blocos diferem em dimensão, informação preditiva e custo. Eliminar o bloco contínuo também elimina interações mistas contínuo×categoria.

Tabela completa do instrumento de medição

Tabela 7 — Saída de summarize(), com cabeçalho traduzido. Acurácia na escala 0–1; dispersão: DP amostral. GFLOP: treino de 100 épocas; MFLOP: uma inferência no teste inteiro. Cada linha agrega três sementes. A referência é `completo_denso_h32` (largura efetiva 64); o sufixo h nas demais linhas é a largura de referência do pareamento. A tabela inclui os custos de todas as ablações da Figura 3. Segundos por execução misturam sessões históricas concorrentes e sessões sequenciais, portanto não comparam latência entre modelos.

configuração	n	acurácia ± DP	treino GFLOP	infer. MFLOP	parâmetros	s/exec
completo_denso_h16	3	0.8546 ± 0.0013	42.15	116.2	3,554	15.5
completo_estrela_h16	3	0.8549 ± 0.0012	41.61	115.2	3,522	15.6
completo_soma_h16	3	0.8557 ± 0.0009	41.61	115.2	3,522	15.2
completo_glu_h16	3	0.8574 ± 0.0003	41.82	116.2	3,522	16.6
completo_geglu_h16	3	0.8538 ± 0.0008	41.98	117.0	3,522	16.7
completo_swiglu_h16	3	0.8545 ± 0.0005	41.87	116.5	3,522	17.4
completo_denso_teto_h16	3	0.8552 ± 0.0006	40.84	112.6	3,443	13.5
completo_denso_h32	3	0.8547 ± 0.0016	84.23	232.4	7,106	32.8
completo_estrela_h32	3	0.8510 ± 0.0020	83.14	230.3	7,042	28.1
completo_soma_h32	3	0.8569 ± 0.0009	83.14	230.3	7,042	28.0
completo_glu_h32	3	0.8574 ± 0.0009	83.56	232.4	7,042	39.0
completo_geglu_h32	3	0.8518 ± 0.0007	83.87	234.0	7,042	32.6
completo_swiglu_h32	3	0.8528 ± 0.0007	83.67	232.9	7,042	45.8
completo_denso_teto_h32	3	0.8548 ± 0.0023	82.91	228.8	6,995	27.2
completo_denso_h64	3	0.8537 ± 0.0008	168.38	464.8	14,210	79.9
completo_estrela_h64	3	0.8481 ± 0.0030	166.21	460.6	14,082	72.6
completo_soma_h64	3	0.8563 ± 0.0008	166.21	460.6	14,082	74.6
completo_glu_h64	3	0.8561 ± 0.0005	167.04	464.8	14,082	61.9
completo_geglu_h64	3	0.8497 ± 0.0013	167.67	467.9	14,082	62.3
completo_swiglu_h64	3	0.8512 ± 0.0005	167.25	465.8	14,082	61.4
completo_denso_teto_h64	3	0.8533 ± 0.0011	165.75	457.5	13,988	38.6
completo_denso_h128	3	0.8520 ± 0.0010	336.67	929.5	28,418	165.9
completo_estrela_h128	3	0.8427 ± 0.0009	332.34	921.2	28,162	119.9
completo_soma_h128	3	0.8572 ± 0.0004	332.34	921.2	28,162	118.7
completo_glu_h128	3	0.8547 ± 0.0001	334.01	929.5	28,162	126.6
completo_geglu_h128	3	0.8460 ± 0.0014	335.26	935.8	28,162	132.6
completo_swiglu_h128	3	0.8484 ± 0.0015	334.42	931.6	28,162	128.5
completo_denso_teto_h128	3	0.8533 ± 0.0003	332.73	918.6	28,085	78.4
continuo_denso_h16	3	0.8211 ± 0.0006	3.89	10.0	290	2.1
continuo_estrela_h16	3	0.8221 ± 0.0007	3.35	8.9	258	2.0
continuo_denso_teto_h16	3	0.8214 ± 0.0010	3.42	8.7	254	1.9
continuo_denso_h32	3	0.8221 ± 0.0010	7.71	19.9	578	3.5
continuo_estrela_h32	3	0.8214 ± 0.0015	6.62	17.8	514	3.1
continuo_denso_teto_h32	3	0.8219 ± 0.0010	6.87	17.7	515	3.2
continuo_denso_h64	3	0.8237 ± 0.0003	15.33	39.7	1,154	6.2
continuo_estrela_h64	3	0.8227 ± 0.0004	13.17	35.5	1,026	6.3
continuo_denso_teto_h64	3	0.8239 ± 0.0011	13.67	35.3	1,028	5.7
continuo_denso_h128	3	0.8241 ± 0.0005	30.59	79.3	2,306	14.5
continuo_estrela_h128	3	0.8232 ± 0.0006	26.25	70.9	2,050	10.8
continuo_denso_teto_h128	3	0.8243 ± 0.0007	27.37	70.9	2,063	13.1
categorico_denso_h16	3	0.8336 ± 0.0010	39.90	110.0	3,362	10.8
categorico_estrela_h16	3	0.8333 ± 0.0008	39.36	109.0	3,330	10.7
categorico_denso_teto_h16	3	0.8342 ± 0.0003	38.66	106.6	3,257	10.3
categorico_denso_h32	3	0.8338 ± 0.0005	79.73	219.9	6,722	26.8
categorico_estrela_h32	3	0.8321 ± 0.0010	78.64	217.8	6,658	20.6
categorico_denso_teto_h32	3	0.8329 ± 0.0008	78.48	216.5	6,617	19.1
categorico_denso_h64	3	0.8319 ± 0.0006	159.37	439.8	13,442	58.2
categorico_estrela_h64	3	0.8272 ± 0.0010	157.21	435.6	13,314	51.5
categorico_denso_teto_h64	3	0.8330 ± 0.0012	156.88	432.9	13,232	37.2
categorico_denso_h128	3	0.8317 ± 0.0006	318.67	879.5	26,882	162.3
categorico_estrela_h128	3	0.8248 ± 0.0017	314.33	871.2	26,626	112.2
categorico_denso_teto_h128	3	0.8306 ± 0.0003	314.93	869.2	26,567	72.3

7. Ameaças à validade

Contabilidade incompleta do motor. Os produtos matriciais dominantes são contados, mas o backward elementar e o Adam não. As ativações recebem custos aproximados; GELU, por exemplo, custa oito operações por elemento no contador. Multiplicação e soma entre ramos têm o mesmo custo registrado, embora seus backwards façam operações diferentes. Igualdade no contador não significa igualdade física exata. FLOPs tampouco medem memória, energia ou latência; os tempos concorrentes não sustentam uma afirmação de aceleração.

Três sementes e comparações múltiplas. O tamanho amostral é mínimo e o IC t tem dois graus de liberdade. Os resultados de cada semente compartilham o mesmo teste oficial; o DP não mede toda a incerteza sobre a população. Avaliar muitas configurações aumenta a chance de uma média extrema. Não usamos o teste para adaptar a grade ou a taxa, mas qualquer escolha posterior da melhor variante é exploratória. Barras sobrepostas não estabelecem equivalência, e separar barras não substitui uma análise estatística completa.

Otimização fixa e escala. A taxa 0,01 e 100 épocas reproduzem a referência, mas não são necessariamente adequadas a cada porta ou largura. Xavier com ramos multiplicativos muda a distribuição das ativações em relação ao denso. Um resultado desfavorável pode indicar dificuldade de treinamento no protocolo, e não incapacidade da classe de funções. O controle soma também muda condicionamento, portanto não separa expressividade de otimização.

Pré-processamento e divisão. O carregador ajusta médias, desvios e vocabulários usando as 32.561 linhas do treino oficial antes da divisão interna. As features da validação influenciam essa transformação; seus rótulos e o teste não. Preservamos esse comportamento para reproduzir a referência e o declaramos como limitação. As sementes mudam simultaneamente inicialização e divisão, impedindo atribuir toda a dispersão a apenas um fator.

Métrica e domínio. Acurácia pode ocultar desempenho desigual na classe minoritária. Não demonstramos melhoria em recall, calibração ou equidade. Adult é uma única base, com 108 features, CPU e float64. Não inferimos desempenho em imagens, grandes modelos de linguagem, GPU, outras precisões ou outras bases. As ablações removem informação e não equivalem a intervenções causais sobre interações específicas.

Pareamento de orçamento. h:2h aproxima o custo apenas no problema completo; a diferença cresce nos contínuos. O denso no teto corrige a restrição de inferência até o arredondamento inteiro, mas não iguala treino, parâmetros ou duração. As fronteiras são calculadas sobre médias; deslocamentos menores que a variabilidade não estabelecem dominância.

8. O que permanece em aberto

O próximo experimento prioritário é ajustar a taxa de aprendizado por família usando somente validação, sob orçamento declarado para a busca, e então repetir em mais sementes. Isso ajudaria a distinguir vantagem arquitetural de uma taxa inadequada. Um desenho com split fixo e várias inicializações, seguido de vários splits, separaria as duas fontes de dispersão.

Para investigar o mecanismo, testar interações controladas em dados sintéticos e perturbar grupos categóricos preservando marginais seria mais informativo que apenas remover blocos. Para generalização, repetir em outras bases tabulares e incluir uma referência de árvores com busca comparável. Para eficiência física, medir inferência isolada, memória e latência com aquecimento e controle de threads; para o uso preditivo, acrescentar métricas por classe e calibração. Nenhuma dessas análises é reivindicada como concluída nesta entrega.

9. Reprodução

Todos os números foram produzidos localmente; não há resultados simulados ou copiados dos artigos. A entrega mantém o instrumento original e depende da cópia completa de BERT-CPU, incluindo `datasets/adult`. Execute os comandos abaixo a partir de `pesquisa/`. O executor pula configurações completas e recusa misturar código/dados com hashes diferentes.

```
python q05_estudo/test_modelos.py --json -v
python q05_estudo/executar.py --processos 1
python q05_estudo/verificar_resultados.py
python q05_estudo/analisar.py
python q05_estudo/gerar_relatorio.py
```

Para reproduzir apenas a auditoria, tabelas e documentos, omita o comando `executar.py`. Para um novo treino independente, use uma cópia integral do repositório e mova os resultados existentes para backup nessa cópia, conforme o README. O notebook abre como relatório e análise dos arquivos salvos; não inicia automaticamente os 156 treinos.

Ambiente de origem: Python 3.14.7, NumPy 2.5.4, CachyOS Linux, Ryzen 5 5600, 16 GB de RAM. Após 51 treinos em três processos, episódios de OOM exigiram retomada sequencial. A coleta de ciclos por época evita acumular grafos; cada filho usa um cgroup próprio, com teto de 3 GiB, swap zero e uma thread BLAS. Pico entre os treinos protegidos: 1,86 GiB; menor MemAvailable monitorado: 6,89 GiB. O backend permaneceu NumPy/CPU float64.

Duração: janela observada da grade: 993,37 min, incluindo interrupções e períodos sem execução; serviços protegidos concluídos: 92,26 min de parede acumulados; soma dos treinos concluídos com referência e validação de equivalência: 117,48 min. A referência original levou 29,67 s e sua validação protegida, 28,43 s. Tempo de pesquisa/redação não foi cronometrado; execuções interrompidas não integram essas somas e o total anterior aos OOMs não é recuperável. Não apresentamos essas durações como comparação de latência entre arquiteturas.

O custo acumulado registrado dos treinos concluídos é 19,120 TFLOPs, incluindo referência e validação de equivalência. Trabalho parcial interrompido não foi salvo nem incluído nesse total. As retomadas históricas preservaram, respectivamente, 36, 51, 51 execuções; a retomada protegida preservou 51. Horários por execução, logs e `sessoes_seguras.jsonl` documentam a continuidade.

Tabela 8 — Principais arquivos (linhas físicas, incluindo comentários)

Arquivo	Linhas
modelos.py	80
executar_seguro.py	240
analisar.py	291
test_modelos.py	263
verificar_resultados.py	211
gerar_relatorio.py	336
proveniencia.py	69
recursos_documentos.py	68
verificar_estrutura.py	87

`resultados/ambiente.json` registra versões, hashes e atributos; `verificacao.json` registra testes e erros de gradiente; `auditoria_final.json` registra verificação de 156 pesos, custos e três inferências recalculadas. Cada JSON individual contém métricas, configuração e curvas; cada NPZ correspondente contém os pesos finais. As tabelas CSV permitem refazer as médias e diferenças sem executar treino. O PDF usa XeLaTeX; Markdown e notebook permanecem acessíveis sem LaTeX.

Referências

[1] MA, X. et al. Rewrite the Stars. CVPR, 2024. https://arxiv.org/abs/2403.19967

[2] SHAZEER, N. GLU Variants Improve Transformer. 2020. https://arxiv.org/abs/2002.05202

[3] DAUPHIN, Y. N. et al. Language Modeling with Gated Convolutional Networks. ICML, 2017. https://arxiv.org/abs/1612.08083

[4] GRINSZTAJN, L.; OYALLON, E.; VAROQUAUX, G. Why do tree-based models still outperform deep learning on tabular data? NeurIPS, 2022. https://arxiv.org/abs/2207.08815